Diseño de pipeline reproducible

Proyecto de Investigación II

Título del plan: Arquitectura híbrida *edge–cloud* para asistente técnico GenAI en Raspberry Pi 5
Dominio: Documentación técnica de soluciones cloud de GenAI (Azure AI Foundry y Amazon Bedrock)
Tipo según guía: LLM + RAG (con política de enrutamiento edge/cloud)

1. Tipo de tesis y objetivo del pipeline

El proyecto es **LLM + RAG**: ante una consulta se recupera evidencia de un corpus documental y un modelo de lenguaje genera la respuesta condicionada a ese contexto. Sobre esa base opera un enrutador predictivo $\pi(x)$: una política ligera (reglas duras de red/PII más un clasificador de bajo costo, p. ej. regresión logística) que, *antes* de generar, asigna la consulta al borde (SLM en Raspberry Pi 5) o a la nube (API de baja latencia). Se calibra con el banco C y se contrasta con políticas fijas y con RouteLLM.

El pipeline debe dejar trazas suficientes para contrastar calidad, latencia, costo y retención local bajo esas ablaciones (PGR y CPT).

2. Diagrama del flujo principal

La Figura 1 muestra el pipeline. Se mantienen separadas tres capas de datos: **(A)** corpus RAG versionado; **(B)** banco de evaluación ($N = 1000$); **(C)** banco del router ($N = 900$), sin solape de identificadores, oraciones gold ni prompts con (B).

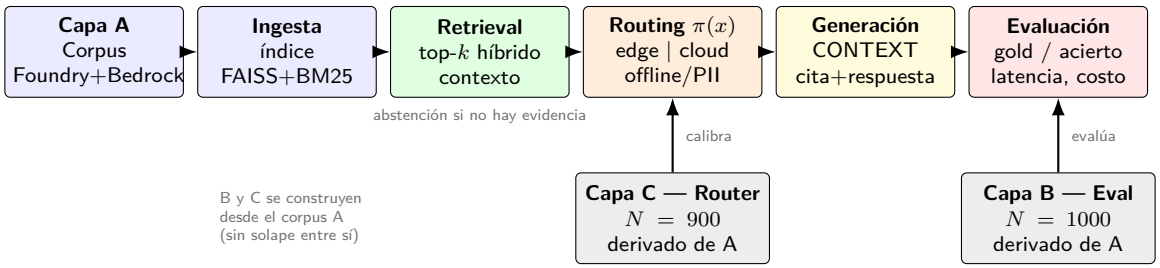


Figura 1: Pipeline LLM + RAG con routing edge–cloud. Arriba: inferencia. Abajo: bancos de datos; C calibra $\pi(x)$ y B sostiene la evaluación.

3. Entradas, componentes y salidas por etapa

Plantilla de salida. Edge y cloud comparten el mismo formato: citas verbatim en inglés tomadas del CONTEXT y una explicación en español. Cuando el CONTEXT no aporta evidencia suficiente, la salida se limita a una abstención explícita.

Parámetros preliminares. Retrieval híbrido (embedding denso + BM25 con fusión por ranking), $k = 5$. En el borde se contempla un SLM tipo Phi-3-mini Instruct cuantizado sobre Raspberry Pi 5; en la nube, un modelo de baja latencia (clase Flash). Un juez automático, de emplearse, será independiente del generador. El laboratorio puede usar backends intermedios para depuración; las mediciones del experimento se reportarán sobre el hardware declarado en el plan.

4. Criterio preliminar de evaluación

La calidad de recuperación se separa de la calidad de generación mediante el acierto documental: si la oración gold figura o no en el CONTEXT recuperado.

Cuadro 1: Entradas y salidas por etapa

Etapa	Recibe	Produce
Ingesta	Docs oficiales (HTML/MD), URL, fecha	Corpus A + inventario versionado (hash por archivo)
Chunking / índice	Texto limpio por sección	≈ 3600 fragmentos; índice denso + léxico
Banco B	Oraciones del corpus + plantillas	Banco de evaluación (500 fáciles / 400 difíciles / 100 PII)
Banco C	Misma familia documental, plantillas distintas	Banco de calibración del router ($N = 900$)
Retrieval	Consulta + índice	top-k fragmentos; score; indicador de acierto documental
Routing $\pi(x)$	Consulta (+ features); red / PII	Decisión edge | cloud (reglas + clasificador ligero)
Generación	CONTEXT + pregunta + plantilla fija	Respuesta estructurada o abstención por falta de evidencia
Evaluación	Respuesta, gold, logs	calidad, calidad condicionada a acierto, latencia, costo, PGR/CPT

Nivel	Criterio (a priori)
Aceptable	Retrieval híbrido con $k = 5$ y proporción de ítems con gold en contexto adecuada para evaluar generación; abstención ante falta de evidencia; registro por consulta.
Mejor	En ablación estratificada, el híbrido con $\pi(x)$ mejora el compromiso latencia–calidad respecto de siempre-edge y siempre-cloud, y cumple CPT$(50\,\%) \leq 0{,}50$ en el marco RouteLLM.
No soporte	El router no mejora el trade-off frente a políticas fijas; una política naive lo iguala o lo supera; o no se alcanza el umbral CPT frente al router de referencia.

Métricas. En retrieval: documento correcto y presencia del gold en contexto (Recall@k operacional). En respuesta: contención del gold en la cita; calidad condicionada al acierto documental; tasa de abstención; fidelidad al contexto. Operativas: latencia (p50/p95), tokens, costo y porcentaje de tráfico local. Como arco académico se emplean PGR y CPT (RouteLLM).

5. Reproducibilidad y control experimental

- **Datos.** Corpus A con inventario (URL, fecha, hash). Bancos B y C congelados con huella criptográfica; el gold se verifica como substring del archivo local.
- **Desarrollo y evaluación.** La capa C calibra $\pi(x)$; la capa B se reserva para ablación y reporte, sin solape de prompts ni oraciones gold.
- **Configuración.** Seed de muestreo; temperatura 0 en evaluación; plantilla de prompt, top-k y modo de retrieval quedan fijados en el registro.
- **Registro por consulta.** Identificador, bloque, fragmentos recuperados, ruta elegida, modelo, respuesta, acierto documental, abstención, calidad, latencia, tokens y costo.
- **Software.** Pipeline versionado; índice regenerable a partir del corpus; auditoría de retrieval sin dependencia de API.

6. Riesgos técnicos y mitigación

1. **Ancla verbal en el prompt.** Si el banco nombra página o sección, el retrieval puede verse favorecido respecto de un usuario real. Mitigación: corrida ciega sin anclas y comparación de ambas condiciones.

2. **Contaminación del cloud.** Documentos públicos pueden haber aparecido en el preentrenamiento. Mitigación: evaluación anclada al CONTEXT y abstención sin evidencia.
3. **Latencia en el borde.** Un SLM de $\sim$3–4 B en Pi 5 puede aumentar la latencia. Mitigación: k y longitud de contexto acotados; medición energética; prueba de sensibilidad con un SLM de menor tamaño.
4. **Respuesta bilingüe.** El gold está en inglés y la explicación en español. Mitigación: puntuar la cita verbatim; juez LLM opcional con proveedor distinto al generador.
5. **Costo de API.** Mitigación: auditoría de retrieval previa a las ablaciones cloud y registro del presupuesto por corrida.

7. Viabilidad

El alcance de este diseño se apoya en un corpus y en bancos B/C locales, en un índice regenerable y en corridas de retrieval sin costo de API. El montaje completo en Raspberry Pi 5 y la comparación con el router publicado de RouteLLM forman parte de la fase experimental posterior.